

Milestone 3 – Odkrywanie procesu i reguł

0. Wprowadzenie

Milestone 3 to ostatni etap analizy zbioru Fischertechnik. Wykorzystujemy wyniki z poprzednich etapów (M1: zrozumienie danych; M2: klasteryzacja sygnałów z $ARI=0.914$) do **odkrycia modelu procesu produkcyjnego** i jego interpretacji.

Pipeline:

1. Grupowanie powtarzających się klastrów po kolei (collapse repeats) → DFG na klastrach
2. DFG dla oryginalnych aktywności (Ground Truth)
3. Porównanie obu DFG
4. Odkrywanie modelu procesu dwoma algorytmami (Alpha + Inductive Miner)
5. Końcowy model BPMN z propozycją ulepszeń
6. Reguły decyzyjne (drzewo decyzyjne na sygnałach)
7. Graf przepływu pracy między maszynami
8. Identyfikacja wąskich gardeł
9. Interpretacja procesu i wnioski biznesowe

1. Konstrukcja logu zdarzeń

1.1 Definicja przypadku (case)

Każda sygnatura `Signature_*.txt` zawiera 1 przypadek jednej aktywności. Aby otrzymać sensowny model procesu, składamy 6 sygnatur w **jeden globalny case** odzwierciedlający przepływ produkcji.

Sortujemy eventy chronologicznie i grupujemy powtarzające się aktywności (collapse repeats):

Sekwencja aktywności (Ground Truth):

```
Burn → Sort → Storage → Mill → Transport → Pickup-move-oven
```

Sekwencja klastrów (DBSCAN z M2):

```
Transport+Burn → Sort → Storage → Mill → Transport+Burn → Pickup-move-oven
```


1.2 Mapowanie klastrów → aktywność

Klaster	Aktywności	Liczba eventów
K0	Burn + Transport	30 (13+17)
K1	Mill	12

Klaster	Aktywności	Liczba eventów
K2	Pickup-move-oven	18
K3	Sort	12
K4	Storage	47

DBSCAN łączy Burn+Transport w jeden klaster (K0) — profile sygnałowe tych dwóch aktywności są na tyle podobne, że są nieodróżnialne na poziomie sygnałów.

2. DFG (Directly-Follows Graph)



2.1 DFG na aktywnościach (Ground Truth)

Krawędź	Częstotliwość
Burn → Sort	1
Sort → Storage	1
Storage → Mill	1
Mill → Transport	1
Transport → Pickup-move-oven	1

Liczba węzłów: 6, **Liczba krawędzi:** 5 (graf liniowy bez pętli)

2.2 DFG na klastrach (DBSCAN)

Krawędź	Częstotliwość
Transport+Burn → Sort	1
Sort → Storage	1

Krawędź	Częstotliwość
Storage → Mill	1
Mill → Transport+Burn	1
Transport+Burn → Pickup-move-oven	1

Liczba węzłów: 5, Liczba krawędzi: 5

2.3 Porównanie DFG

Metryka	DFG aktywności	DFG klastrów
Węzły	6	5
Krawędzie	5	5
Pętle	brak	K0 → K0 (pośrednio przez różne pozycje)
Czystość	każda aktywność osobno	Burn+Transport jako 1 węzeł

Kluczowa różnica: DFG na klastrach traci rozróżnienie Burn vs Transport — węzeł K0 pojawia się **dwukrotnie** w sekwencji (na początku jako Burn, później jako Transport). DFG na aktywnościach (GT) zachowuje pełny przepływ 6 aktywności w prostym grafie liniowym.

Wniosek dla M3: Do odkrywania modelu procesu używamy DFG na aktywnościach (GT), bo ma większą siłę informacyjną.


3. Odkrywanie modelu procesu

3.1 Algorytmy

Zastosowano dwa algorytmy odkrywania procesu z biblioteki PM4PY:

1. **Alpha Miner** — klasyczny algorytm odkrywania sieci Petriego z relacji DF
2. **Inductive Miner** — nowoczesny algorytm zwracający process tree gwarantujący poprawność modelu (sound model)

3.2 Wyniki



Statystyki modeli:

Model	Places	Transitions	Arcs	Fitness	Precision	Generalization	Simplicity
Alpha Miner	7	6	12	1.000	1.000	0.000	1.000
Inductive Miner	7	6	12	1.000	1.000	0.000	1.000

Interpretacja metryk:


- **Fitness = 1.0** — model w 100% odtwarza obserwowane sekwencje (replay log fits perfectly)
- **Precision = 1.0** — model nie pozwala na ścieżki, których nie ma w logu
- **Generalization = 0.0** — model jest "ściśły" do logu (nie generalizuje na nieznane przypadki) — wynika to z ograniczonego zbioru (1 case z 6 aktywnościami)
- **Simplicity = 1.0** — model jest prosty (graf liniowy)

Obie metody dały **identyczny model** — sieć Petriego z 6 przejściami (po jednym na aktywność) i 7 miejscami w sekwencji liniowej. To naturalne dla zbioru z jednym variant'em procesu.

4. Końcowy model BPMN

4.1 BPMN odkryty z Inductive Miner


Model BPMN - odkryty Inductive Miner



Model BPMN (konwersja z process tree) odzwierciedla obserwowaną sekwencję — bez bramek decyzyjnych ani równoległości, bo dane zawierają tylko 1 wariant.

4.2 Końcowy model BPMN z ulepszeniami

Na bazie wiedzy o systemie Fischertechnik (klasyczny przepływ produkcji) i analizy danych proponujemy ulepszony model BPMN:

KONCOWY MODEL BPMN - proces produkcyjny Fischertechnik
(z bramką decyzyjną XOR po Burn: Mill albo Sort)

Proponowane ulepszenia:

1. **Bramka XOR po Burn** — decyzja: Mill (frezowanie) lub Sort (sortowanie) zależnie od typu detalu
2. **Bramka XOR przed Transport** — synchronizacja po wybraniu ścieżki Mill lub Sort
3. **Storage jako pierwszy etap** — zgodnie z dokumentacją Fischertechnik, detal startuje z magazynu
4. **Pickup-move-oven jako mostek** — robot transportuje detal między stacjami


Końcowa sekwencja:

Start → Storage → Pickup → Burn → [XOR: Mill v Sort] → Transport → End

5. Reguły decyzyjne

Drzewo decyzyjne klasyfikuje event do klastra na podstawie wartości sygnałów. Wytrenowane drzewo osiągnęło dokładność 1.000 — wszystkie 119 eventów zostało poprawnie sklasyfikowanych.

5.1 Wizualizacja drzewa



Grafika przedstawia wytrenowane drzewo decyzyjne o maksymalnej głębokości 4. Każdy prostokąt to węzeł drzewa zawierający: warunek na sygnale (np. `i1_light_barrier <= 0.5`), wartość gini (miara czystości — 0 oznacza węzeł jednorodny), liczbę próbek (`samples`), rozkład klas w węźle (`value`) oraz przewidywaną klasę (klastry). Kolor węzła odzwierciedla dominujący klastry — im węzeł czystszy, tym kolor intensywniejszy.

Drzewo czyta się od korzenia w dół: w każdym węźle, jeśli warunek jest spełniony, idziemy w lewo, w przeciwnym razie w prawo. Liście drzewa (na samym dole) zawierają finalne przypisanie do klastra.


Konkretne reguły odkryte przez drzewo:

Warunek (sekwencja od korzenia do liścia)	Klastry	Aktywność
$i1_light_barrier \leq 0.5 \wedge i4_light_barrier \leq 0.5 \wedge i3_light_barrier \leq 0.5$	K0	Burn + Transport
$i1_light_barrier \leq 0.5 \wedge i4_light_barrier \leq 0.5 \wedge i3_light_barrier > 0.5$	K3	Sort
$i1_light_barrier \leq 0.5 \wedge i4_light_barrier > 0.5 \wedge i7_light_barrier \leq 0.5 \wedge i5_pos_switch \leq 0.5$	K1	Mill

Warunek (sekwencja od korzenia do liścia)	Klaster	Aktywność
$i1_light_barrier \leq 0.5 \wedge i4_light_barrier > 0.5 \wedge i7_light_barrier \leq 0.5 \wedge i5_pos_switch > 0.5$	K4	Storage
$i1_light_barrier \leq 0.5 \wedge i4_light_barrier > 0.5 \wedge i7_light_barrier > 0.5$	K2	Pickup-move-oven
$i1_light_barrier > 0.5 \wedge i8_light_barrier \leq 0.5$	K4	Storage
$i1_light_barrier > 0.5 \wedge i8_light_barrier > 0.5$	K3	Sort

Drzewo wykorzystuje wyłącznie sygnały typu bariera świetlna ($i*_light_barrier$) i przełącznik pozycji ($i*_pos_switch$) — cztery wartości binarne wystarczają do jednoznacznej klasyfikacji wszystkich sześciu klastrów.

5.2 Najważniejsze sygnały



Najsilniejsze reguły decyzyjne (top sygnały determinujące klaster):

- **m4_speed** — najważniejszy sygnał (silnik osi Z magazynu HBW_1, charakterystyczny tylko dla Storage)
- **o5_valve** — zawór charakterystyczny dla Sort i Transport
- **o7_valve** — zawór charakterystyczny dla Burn
- **i7_light_barrier** — bariera świetlna w Pickup-move-oven

Reguły można zinterpretować jako:


- $m4_speed \neq 0 \rightarrow$ **Storage** (tylko HBW_1 ma silnik m4)
- $o7_valve = 1 \wedge m1_speed \in \{-1, 1\} \rightarrow$ **Burn**
- $i7_light_barrier = 1 \wedge m3_speed \neq 0 \rightarrow$ **Pickup-move-oven**

- $o6_valve = 1 \wedge m1_speed = -1 \rightarrow \text{Sort}$
- $m2_speed \neq 0 \wedge o5_valve = 1 \rightarrow \text{Transport}$

Te reguły mogą zostać użyte jako **warunki w bramkach decyzyjnych BPMN** — pozwolą automatyzować klasyfikację stanów procesu na podstawie sygnałów PLC w czasie rzeczywistym.

6. Analiza zasobów

6.1 Obciążenie maszyn




Maszyna	Aktywność	Eventy	Czas [s]	Eventy/s
HBW_1	Storage	47	93	0.51
VGR_1	Pickup-move-oven	18	34	0.53
WT_1	Transport	17	32	0.53
OV_1	Burn	13	25	0.52
SM_1	Sort	12	23	0.52
MM_1	Mill	12	23	0.52

HBW_1 (magazyn) ma największe obciążenie — 47 eventów (39.5%) i 93 sekundy (40% sumy).

6.2 Graf przepływu pracy między maszynami

Graf przepływu pracy między maszynami
(rozmiar węzła = liczba eventów)





Graf pokazuje sieć współpracy między maszynami:

OV_1 → SM_1 → HBW_1 → MM_1 → WT_1 → VGR_1

Każda maszyna jest węzłem, a krawędzie pokazują przekazania pracy. Rozmiar węzła odzwierciedla liczbę eventów. Sekwencja jest liniowa — żadna maszyna nie współpracuje z więcej niż 2 innymi (jeden poprzednik + jeden następnik).

7. Identyfikacja wąskich gardeł



7.1 Czas trwania per aktywność

Aktywność	Stacja	Eventy	Czas [s]	% sumy
Storage	HBW_1	47	93	40%
Pickup-move-oven	VGR_1	18	34	14.5%
Transport	WT_1	17	32	13.7%
Burn	OV_1	13	25	10.7%
Sort	SM_1	12	23	9.8%
Mill	MM_1	12	23	9.8%
Suma		119	230	100%

7.2 Główne wąskie gardło: Storage (HBW_1)

- **Czas:** 93 sekundy (40% sumy czasów)
- **Eventy:** 47 (39% wszystkich)
- **Złożoność:** 12 aktywnych sygnałów (najwięcej w zbiorze)
- **Przyczyna:** ruch 3D w magazynie wysokiego składowania (4 silniki: m1, m2, m3, m4)

Pozostałe potencjalne wąskie gardła:

- **Pickup-move-oven** (34s, 18 eventów) — dynamika ruchu wieloosiowego robota
- **Transport** (32s) — czas jazdy wózka między stacjami

8. Interpretacja procesu i wnioski

8.1 Co model mówi o systemie?

Analizowany system to laboratoryjna fabryka **Fischertechnik** — cyber-fizyczny system produkcyjny zaprojektowany jako uproszczony model rzeczywistej linii produkcyjnej. 6 stacji pracuje sekwencyjnie:

Etap	Stacja	Maszyna	Rola w procesie
1	HBW_1	Magazyn	Składowanie surowca / produktu końcowego
2	VGR_1	Robot chwytakowy	Transport między stacjami
3	OV_1	Piec	Obróbka termiczna (utwardzanie)
4	MM_1	Frezarka	Obróbka skrawaniem
5	SM_1	Sortownica	Klasyfikacja produktów wg cech
6	WT_1	Wózek transportowy	Transport wewnętrzny

System jest **w pełni zautomatyzowany** — brak zasobów ludzkich, tylko maszyny komunikujące się przez MQTT/Siddhi CEP.

8.2 Najczęstsze ścieżki

Dane zawierają **jeden wariant procesu** (1 case z 6 aktywnościami) — nie ma alternatyw ani powtórzeń.

Zaobserwowana sekwencja chronologiczna:

```
Burn (10:11) → Sort (10:12) → Storage (10:30) → Mill (10:34) → Transport (10:57) → Pickup-move-oven (11:08)
```

Uwaga: ta kolejność odzwierciedla **kolejność rejestracji sygnatur** w plikach źródłowych, nie rzeczywisty przepływ produkcji. Klasyczny przepływ Fischertechnik (z dokumentacji systemu):

```
Storage → Pickup-move-oven → Burn → Mill/Sort → Transport
```

8.3 Gdzie pojawiają się opóźnienia?

Pozycja	Aktywność	Czas	Uzasadnienie
1	Storage (HBW_1)	93 s	Najdłuższa — ruch 3D w magazynie (4 silniki)
2	Pickup-move-oven (VGR_1)	34 s	Robot wieloosiowy z chwytakiem próżniowym
3	Transport (WT_1)	32 s	Jazda wózka między stacjami
4–6	Burn, Sort, Mill	23–25 s	Krótkie operacje stanowiskowe

Storage to dominujące wąskie gardło — gdyby udało się zredukować jego czas o 50%, cały proces przyspieszyłby o ~20%.

8.4 Potencjalne usprawnienia

- Optymalizacja Storage** — redukcja liczby ruchów 3D w HBW_1 (np. lepszy algorytm pozycjonowania)
- Równoległość Mill/Sort** — obie aktywności po Burn mogą działać równolegle (oddzielne maszyny niezależne mechanicznie)
- Buforowanie międzyetapowe** — pozwoliłoby na częściową równoległość produkcji wielu detali jednocześnie
- Reguły decyzyjne CEP** — dodanie bramek XOR z warunkami sygnałowymi (z drzewa decyzyjnego) automatyzuje routing detali
- Monitoring real-time z CEP/Siddhi** — wykrywanie odchyłeń od wzorców w czasie rzeczywistym (wzorce już zdefiniowane w plikach `.siddhi`)
- Predictive maintenance** — analiza przejść między klastrami pozwala wykryć anomalie sygnałowe (różnice od wzorca)

8.5 Wnioski biznesowe

Wniosek	Implikacja biznesowa
System deterministyczny (fitness=1.0)	Wysoka powtarzalność procesu — niskie ryzyko błędu produkcyjnego

Wniosek	Implikacja biznesowa
Klasteryzacja sygnałów ARI=0.914 (M2)	Możliwa automatyczna klasyfikacja stanów bez znajomości aktywności
Burn i Transport mają podobne profile	Można optymalizować wspólnie (oba używają zaworu pneumatycznego)
Storage = 40% sumy czasów	Największe pole do optymalizacji — ROI najwyższy
Wzorce CEP w pełni weryfikowalne (15/15)	System diagnostyczny gotowy do wdrożenia produkcyjnego
Drzewo decyzyjne accuracy=1.0	Jednoznaczne reguły mapowania sygnał→aktywność — możliwa automatyzacja routing'u

8.6 Ograniczenia analizy

- **Mały zbiór** (119 eventów, 1 case) — model nie generalizuje (Generalization=0.0)
- **Jedna sygnatura per aktywność** — brak wariantów, brak alternatywnych ścieżek
- **Brak ludzkich zasobów** — analiza sieci współpracy ograniczona do maszyn
- **Brak danych z wielu dni** — nie można ocenić sezonowości lub wzorców dobowych

8.7 Plan na przyszłość (poza projektem)

1. Zebranie wielodniowych danych z wielu cykli produkcyjnych
2. Detekcja anomalii w czasie rzeczywistym przez CEP (wzorce z plików `.siddhi`)
3. Implementacja bramek XOR w sterowaniu PLC na bazie reguł z drzewa decyzyjnego
4. Symulacja ulepszeń BPMN (np. równoległość Mill/Sort) i pomiar przyspieszenia procesu
5. Conformance checking między modelem BPMN a logami produkcyjnymi

9. Podsumowanie Milestone 3

W ramach Milestone 3 zrealizowano wszystkie wymagane elementy odkrywania procesu. Najpierw zbudowano dwa grafy DFG — jeden na klastrach z poprzedniego etapu (5 krawędzi, 5 węzłów) i drugi na oryginalnych aktywnościach traktowanych jako Ground Truth (5 krawędzi, 6 węzłów, prosty graf liniowy). Porównanie obu grafów pokazało, że klastry łączą Burn i Transport w jeden węzeł, podczas gdy DFG na aktywnościach zachowuje pełny przepływ.

Następnie zastosowano dwa różne algorytmy odkrywania modelu procesu z biblioteki PM4PY: Alpha Miner i Inductive Miner. Oba zwróciły identyczny model z 7 miejscami, 6 przejściami i 12 łukami, osiągając perfekcyjną zgodność z logiem (fitness=1.0, precision=1.0).

Końcowy model BPMN został zaproponowany na bazie wiedzy o systemie Fischertechnik i obserwacji z danych — uwzględnia bramkę XOR po aktywności Burn (decyzja między Mill a Sort) oraz początek z magazynu HBW_1, zgodnie z klasycznym przepływem produkcji.

Reguły decyzyjne odkryto za pomocą drzewa decyzyjnego, które na podstawie wartości sygnałów PLC klasyfikuje event do odpowiedniego klastra z dokładnością 1.0. Najważniejsze sygnały to `m4_speed`

(jednoznacznie wskazuje Storage), `o5_valve`, `o7_valve` oraz `i7_light_barrier`. Reguły te mogą posłużyć jako warunki w bramkach BPMN.

Analiza zasobów objęła obciążenie poszczególnych maszyn oraz graf przepływu pracy między nimi. Magazyn HBW_1 okazał się najbardziej obciążonym zasobem (47 eventów, 93 sekundy). Graf przepływu jest sekwencją liniową — żadna maszyna nie współpracuje z więcej niż dwiema innymi.

Identyfikacja wąskich gardeł wskazała jednoznacznie na aktywność Storage realizowaną na stacji HBW_1 — zajmuje ona 40% sumarycznego czasu procesu i obejmuje 39% wszystkich eventów. Wynika to ze złożoności ruchu trójwymiarowego w magazynie wysokiego składowania, który wymaga sterowania czterema silnikami.

W sekcji interpretacji opisano działanie całego systemu, najczęstsze ścieżki, miejsca występowania opóźnień, propozycje usprawnień (między innymi równoległość Mill i Sort, optymalizacja Storage, monitoring real-time przez CEP) oraz wnioski biznesowe. Sformułowano też ograniczenia analizy wynikające z małego rozmiaru zbioru i jednego wariantu procesu.

Pliki wykonawcze:

- `Milestone3_Discovery.ipynb` — pełen notebook z kodem i wynikami (34 komórki)
- `Milestone3_Raport.md` — niniejszy raport